

Germline Small-Variant Annotation and Pathogenicity Classification on NCHC (Hands-on)

A VEP-based annotation and point-based in-house ACMG classification workflow for germline small variants

Workflow developed by 李婕瑜 (Chieh-Yu Lee) • 袁自航 (Tzu-Hang Yuan) • Dr. 陳俞安 (Dr. Yu-An Chen)

Advisors: Dr. 陳沛隆 (Dr. Pei-Lung Chen) • Dr. 許書睿 (Dr. Jacob Shu-Jui Hsu) • Dr. 陳倩瑜 (Dr. Chien-Yu Chen)

Computation on NCHC • Draft 2026.

Germline Small-Variant Annotation and Pathogenicity Classification on NCHC (Hands-on)

Germline small variant 致病性分析 · 操作手冊 (Hands-on). 適用需在國網重建此流程的使用者。

本手冊涵蓋三段流程：① VEP 註解 → ② ACMG 致病性分類 → ③ 條件篩選。VEP 的輸出（`.vep.tsv`）是 ACMG 的輸入，ACMG 的輸出（`.vep.ACMG.tsv`）是篩選的輸入，請依序執行。

本版重點 ① 新增 `submit.sh` 支援 `sample.list` 提交。② `filter_acmg.py` 位於 `ACMG_filter/`，同資料夾附 `run_filter.sh`、`gene.list`。③ conda 環境安裝位置可自行選擇（`/home/<帳號>/` 或 `/work/<帳號>/` 下）。④ VEP 完成後可自動接 ACMG（`RUN_ACMG` 開關）。⑤ 篩選分「分類模式（OR）／流程模式（AND）」兩種，輸出一律自動含 `ACMG_point`。

0. 改成自己的：

項目	範例值	換成
帳號（所有 <code>/work</code> 路徑）	d03455002	你的登入帳號 → <code>/work/<帳號>/VEP-ACMG</code>
計畫代號 #SBATCH -A	MST109178	你 iService 的計畫 ID
通知信 <code>--mail-user</code>	you@example.com	你的 email

不要改 所有 `/staging/reserve/jacobhsu/reference/VEP/...`（參考基因組、VEP cache、plugins、ClinVar/gnomAD 等 custom annotation、ACMG 的 `config.json` 資料庫路徑）。這是實驗室共用資料，有讀取權限就直接用。先驗證：`ls /staging/reserve/jacobhsu/reference/VEP/` 列得出東西即可。

1. 目錄結構（最終長這樣）

```
/work/<帳號>/VEP-ACMG/
├── VEP-small_variant/          # VEP 註解
│   ├── 00_vep_batch_submitter.py
│   ├── 01_preprocess.sh
│   ├── 02_submit_vep.sh
│   ├── 02_vep.sh
│   └── 03_post_vep.sh
├── ACMG-small_variant/        # ACMG 分類
│   ├── acmg_batch_submitter.sh # 自行跑 ACMG 分類 (Stage 5)
│   ├── sample_acmg.list       # 自行跑 ACMG 分類需設定
│   ├── run_acmg.sh
│   ├── main.py
│   └── modules/
│       ├── acmg_rules.py
│       ├── aggregation.py
│       └── data_loader.py
├── ACMG_filter/
│   ├── rescore.py             # 自訂每個規則的分數以及分類的閾值
│   ├── run_filter.sh          # 設定檔式啟動器 (Stage 6)
│   ├── filter_acmg.py         # 篩選腳本 (Stage 6)
│   └── gene.list              # --gene-list 用的基因清單 (預設空)
├── utils/
│   ├── VEP/
│   ├── ACMG/
│   │   ├── config.json
│   │   └── hg38_BA1exc.tsv
│   ├── job_utils.sh
│   ├── environment.yml
│   └── setup_env.sh           # 互動式安裝 conda 環境 (Stage 2)
├── input_vcf/                 # 你的輸入 VCF
├── sample.list                 # VEP 要跑哪些 case (自訂)
├── results/                   # 所有輸出
│   ├── sample/
│   │   ├── VEP_output/
│   │   ├── ACMG_output/
│   │   ├── scripts/
│   │   ├── logs/
│   │   └── sample_submit.sh
│   └── logs/
├── config.sh                  # 設定 (Stage 3)
└── submit.sh                  # 一鍵送出腳本 (Stage 4)
```

2. Stage 0 • 登入

```
ssh <帳號>@t3-c4.nchc.org.tw # 登入國網
```

3. Stage 1 • Clone github repo

```
cd /work/<帳號>
git clone https://github.com/leechiehyu/VEP-ACMG.git
```

4. Stage 2 • 建立環境

2-1 VEP：不用安裝。VEP 使用系統 module 與已裝好的共用 conda 環境（/opt/ohpc/Taiwania3/pkg/biology/vep/vep_v115），只要能 load module。

2-2 ACMG：建立 conda 環境 acmg_rule。

只需在第一次使用時執行。

```
cd /work/<帳號>/VEP-ACMG/utils
bash setup_env.sh
```

會出現以下互動式選項，可根據使用習慣設定 conda 環境安裝路徑：

Conda Environment Auto-Installer

請選擇您的 Conda 環境安裝路徑：

- 1) /home/user/.conda/envs/ (預設路徑)
- 2) /work/user/.conda/envs/
- 3) 自訂路徑 (手動指定環境與快取路徑)

請輸入選項 (1/2/3):

選項 1 會按照 conda 預設安裝方式將環境建在家目錄下。選項 2 會將環境建在 /work/<帳號>/VEP-ACMG/utils/.venv/ 下。

5. Stage 3 • 設定參數

修改 config.sh 頂端自訂區塊。

```
# Fill the mail address if you want to receive email notifications when the job ends or fails.
export USERMAIL=""

# Your working directory (i.e., where this script is located)
export WKDIR="/work/${USER}/VEP-ACMG"

# Automatically run ACMG after VEP completion
## 1 = annotation + pathogenicity classification
## 0 = Only annotation
export RUN_ACMG=1
```

如果 VEP-ACMG/ 資料夾是建在 /work/<帳號>/ 下，不需改動。

Automatically run ACMG after VEP completion 見 6.1 說明。

6. Stage 4 • 執行 VEP 註解

流程：把 *.vcf 或是 *.vcf.gz 放進 input_vcf/ → 在 sample.list 列出要跑的 case → 送出 submit.sh。submit.sh 依 sample.list 只挑指定 case，自動送出 preprocess → VEP array → merge 三段 job。

如果不會編輯檔案或是要跑所有 input_vcf/ 中的樣本，可以直接執行 submit.sh 不需編輯 sample.list，但要確保 input_vcf/ 中有檔案。

```
# 1) 放輸入 VCF 到 input_vcf/
# 2) 編輯 sample.list (一行一個，# 開頭跳過)
# 3) 送出
cd /work/<帳號>/VEP-ACMG
bash submit.sh
queue --me
```

sample.list 寫法 每行可為 ① 完整檔名 (xxx.vcf.gz) ② 樣本 ID (xxx，自動補 .vcf.gz / .vcf) ③ 短 ID 前綴 (如 A5034E，自動對到 input_vcf/A5034E*.vcf.gz，排除 .tbi 與 .gvcf.gz)。用短 ID 時輸出樣本名就用該短 ID。一個前綴對到多個檔會警告，請改寫更完整名稱。

在 sample.list 中有問題的寫法／樣本會記錄在 results/skipped_samples.warnings 中，沒有出現這個檔案代表寫法沒有問題。

每個樣本完成後，在 results/<樣本>/VEP_output/ 產生 <樣本>.vep.tsv (ACMG 輸入) 與 <樣本>.vep.mane_plus_clinical.tsv。

6.1 VEP 完自動接 ACMG

送出 submit.sh 後，每個 sample 的 VEP 三段 job 跑完，會用 Slurm 相依性自動送出該 sample 的 ACMG 分類，不需再手動執行 acmg_batch_submitter.sh。

如何設定 RUN_ACMG：開關就寫在 config.sh 頂端的「自訂」區。預設已是 1 (VEP 完自動接 ACMG)；若只想跑 VEP、之後再自己做 Stage 5，改成 0 即可。改好存檔後照常 bash submit.sh。

7. Stage 5 • 執行 ACMG 分類 (手動／批次，選用)

已啟用自動串接者可略過本段；本段用於 RUN_ACMG=0、補跑或一次重跑全部樣本。

5-1 設定輸入樣本檔案路徑。將所有需要跑 ACMG 分類的檔案「絕對路徑」列在 sample_acmg.list 中。

如果不會編輯檔案或是要跑所有 results/ 中的樣本，可以直接執行 ACMG-small_variant/acmg_batch_submitter.sh 不需編輯 sample_acmg.list。

在 sample_acmg.list 中有問題的寫法／樣本會記錄在 results/acmg_skipped_samples.warnings 中，沒有出現這個檔案代表寫法沒有問題。

5-2 手動送出：

```
cd /work/<帳號>/VEP-ACMG/ACMG-small_variant
bash acmg_batch_submitter.sh
queue --me
```

結果在 /results/<樣本>/ACMG_output/：<樣本>.vep.ACMG.tsv 與 <樣本>.vep.mane_plus_clinical.ACMG.tsv（含 Pathogenicity_class、ACMG_rules）。

8. Stage 6 • 條件篩選 (filter_acmg.py)

位於 `ACMG_filter/`。分兩種互斥模式（自動判定），輸出一律自動補上 `ACMG_point` 欄位。用 `-h` 看 option（`-h` 免啟用環境即可看）；`--list-columns` 列出全部欄位。

- 分類模式：用到 `--plp` / `--clinVar-plp` / `--dvd-plp` 任一個 → 結果 = 它們的 OR 聯集，且忽略下方所有流程條件。
- 流程模式：完全不用分類旗標時，才依固定順序做 AND 篩選。

8.1 方式 A：設定檔式啟動器 run_filter.sh（建議）

同資料夾內的 `run_filter.sh` 已把環境啟用與路徑處理包好，修改「2) 篩選條件」把要用的條件行前的 `#` 拿掉即可。執行的時候加上要執行的檔案名稱 (e.g., `A5034E.vep.ACMG.tsv`)。

```
cd /work/<帳號>/VEP-ACMG/ACMG_filter
bash run_filter.sh <檔案名稱> # 也可 sbatch run_filter.sh <檔案名稱> 丟進 Slurm
```

檔案路徑注意 輸入檔案名稱後會尋找 `results/<樣本>/ACMG_output/`，不需給完整路徑。log 位置 log 一律寫到 `results/logs/`。

8.2 方式 B：直接呼叫 filter_acmg.py

```
cd /work/<帳號>/VEP-ACMG/ACMG_filter
source ../config.sh
activate_conda_env
python filter_acmg.py -i <input>.vep.ACMG.tsv -o <out>.tsv [options]
```

8.3 選項（一）分類模式（獨立；OR 聯集；忽略流程條件）

Option	作用
<code>--plp</code>	ACMG Pathogenicity_class = Pathogenic / Likely_pathogenic
<code>--clinVar-plp</code>	ClinVar_CLNBSIG = Pathogenic / Likely_pathogenic（ <code>--ex-blb</code> 的相對版）
<code>--dvd-plp</code>	DVD 分類 = Pathogenic / Likely_pathogenic

8.4 選項（二）流程模式（AND；依此固定順序）

#	Option	作用
1	<code>--pass-only</code>	只留 FILTER = PASS
2	<code>--min-dp INT</code>	保留 DP ≥ 值（空值濾掉）
3	<code>--acmg-ex RULE[,RULE]</code>	刪除 ACMG_rules 含指定精確 token 者（如 BA1）
—	<code>--ex-blb</code>	去掉 ClinVar 純良性（含 B/LB 且無 conflicting/VUS/P）
4	<code>--min-vaf FLOAT</code>	保留 VAF ≥ 值（空值濾掉）
—	<code>--max-af FLOAT</code>	genome_AF 與 exome_AF 皆 ≤ 值（空值保留）；0.01 / 0.05
5	<code>--gene-list PATH</code>	只留 SYMBOL 在基因清單中的位點（一行一個）
6	<code>--exonic / --noncoding</code>	只留第 1 類 exonic+splice / 只留非第 1 類（擇一）
7	<code>--consequence + --mode</code>	自訂 Consequence 關鍵字；--mode include/exclude
8	<code>--acmg-ex-b-rule-only</code>	刪除只有 B 證據、無 P 證據者
9	<code>--vushigh</code>	只留 ACMG_point 總分 ≥ 3（VUS-high）

共用：`--list-columns` / `-v`（列欄位 / 顯示每步剩餘列數）。你打 option 的先後不影響結果（AND 交集與順序無關；只有 `-v` 中間計數依固定順序）。

8.5 ACMG 點數規則（一律自動計算 ACMG_point）

P 開頭為正、B 開頭為負；`_修飾`（`_VERYSTRONG` / `_STRONG` / `_MODERATE` / `_SUPPORTING`）覆蓋等級。`--vushigh` 只留總分 ≥ 3 。

等級	Pathogenic (+)	Benign (-)
very strong	PVS = +8	BA = -8
strong	PS = +4	BS = -4
moderate	PM = +2	BM = -2
supporting	PP = +1	BP = -1

例：`PVS1,PM2` = $8+2=10$ ；`PVS1_STRONG` = +4；`BP6_STRONG` = -4；`BA1` = -8。

8.6 範例

```
# 分類模式：留 ACMG-P/LP 或 DVD-P/LP 的聯集（自動含分數）
python filter_acmg.py -i MDD261-PKD.vep.ACMG.tsv -o class.tsv --plp --dvd-plp -v

# 流程模式：PASS + 去 BA1 + coding + VUS-high (AND)
python filter_acmg.py -i MDD261-PKD.vep.ACMG.tsv -o flow.tsv \
    --pass-only --acmg-ex BA1 --exonic --vushigh -v
```

9. 運算資源（各 script 的 SBATCH 設定）

Script	分區	cores	記憶體	備註
01_preprocess.sh	ngs13G	2	13 GB	VCF 正規化、切染色體
02_submit_vep.sh	ngs7G	1	7 GB	控制/送 array
02_vep.sh	ngs92G	14	92 GB	VEP 註解 (array)
03_post_vep.sh	ngs7G	1	7 GB	合併、產 TSV
run_acmg.sh	ngs26G	4	26 GB	ACMG 分類 (array)
run_filter.sh	ngs7G	1	7 GB	條件篩選（選用 sbatch）